

(temp) Extração e Seleção de Características de sinais de EEG para diagnóstico de distúrbios neurológicos

Wallace Faveron de Almeida, *Mestrando, PPgSI*

Abstract—A análise dos sinais de EEG tem diversas aplicações na área médica. Ela é extensamente utilizada para diagnósticos clínicos e para avanços na área de Interface Cérebro-Computador (BCI). Nos últimos anos, diversos estudos a respeito da execução automática dessa análise foram propostos, motivados pelo fato da atividade tradicional demandar muito tempo de um especialista, além de estar sujeita a um diagnóstico equivocado. Apesar de apresentarem boa acurácia, muitos dos métodos atuais não são apropriados para uma aplicação *on-line* devido ao seu alto custo computacional. Dessa forma, existe oportunidade na área para estudos que proponham a otimização dessa atividade.

Index Terms—Feature Extraction, Feature Selection, EEG, Entroencephalogram, diagnosis, neural disease.

1 INTRODUÇÃO

2 REFERENCIAL TEÓRICO

2.1 Técnicas de Extração de Características (*Feature Extraction - FE*)

2.1.1 Análise espectral de Hilbert-Huang - (*Empirical Mode Decomposition - EMD*)

A Análise espectral de Hilbert-Huang (*Empirical Mode Decomposition - EMD*) é um método para análise de sinais no domínio de tempo-frequência (*time-frequency*) proposto originalmente em [1]. Esse método utiliza uma abordagem direcionada pelos dados, não sendo necessário assumir uma definição prévia como uma função-mãe *wavelet*, decompondo o sinal de entrada de maneira adaptativa em um número finito de funções, limitadas por frequência, denominadas (*Intrinsic Mode Functions IMFs*). [2] [3].

As *IMFs* podem ser aplicadas na análise de sinais não-lineares e não-estacionários. Cada *IMF* deve satisfazer duas condições básicas [2]:

- (1) Em todo o conjunto de dados, o número de pontos extremos e o número de cruzamento zero devem ser iguais ou diferir em no máximo um;
- (2) Em cada ponto, o valor médio dos envelopes definidos pelo máximo local e o mínimo local deve ser zero.

O princípio da *EMD* é fundamentado na decomposição do sinal original $x(t)$, possivelmente composto por diversas frequências, em n *IMFs* com frequência única, mais um sinal residual. [4]. Assim, o sinal original pode ser recuperado por meio da combinação linear:

$$x(t) = \sum_{n=1}^N imf_n(t) + r(t) \quad (1)$$

Um meio sistemático de obter *IMFs*, consiste um processo de peneirar (*sifting*) é indicado abaixo [2]:

Dado um sinal de entrada $x(t)$, $r(t) = x(t)$ e $n = 0$.

- Passo1 Obtenha o conjunto de máximos e o conjunto de mínimos locais de $x(t)$;
- Passo2 Obtenha o envelope superior $e_{max}(t)$ por conectar todos os máximos através de funções *splines* cúbicas. Repita o procedimento para conectar todos os mínimos locais e obtenha o envelope inferior $e_{min}(t)$;
- Passo3 Calcule o valor médio para cada ponto dos envelopes: $m(t) = (e_{max}(t) + e_{min}(t))/2$;
- Passo4 $h(t) = x(t) - m(t)$. Se $h(t)$ satisfaz as condições de então $n = n + 1$, $imf_n = h(t)$ e vá para o passo 5, caso contrário $x(t) = h(t)$ e retorne para o ciclo 1-4;
- Passo5 Seja $r(t) = r(t) - imf_n$. Se $r(t)$ é uma função monotônica encerre o processo de peneirar, caso contrário $x(t) = r(t)$ e retorne ao passo 1.

Conforme descrito em [1], para garantir que cada *IMF* armazene informação suficiente para amplitude e frequência, é necessário estabelecer um critério de parada para o processo de peneirar. Isso pode ser realizado estabelecendo um valor de corte para o desvio padrão (DP), calculado a partir de duas iterações seguidas como:

$$DP = \sum_{t=1}^T \left[\frac{(h_1(k-1) - h_1(k))^2}{h_1^2(t)} \right] \quad (2)$$

• W. F. Almeida - Escola de Artes, Ciências e Humanidades, Universidade de São Paulo, São Paulo - SP, Brazil.
E-mail: wallace.almeida (no domínio usp.br)

Artigo recebido em 15 de Junho de 2018; revisado ?

2.1.2 Transformada discreta de Wavelet - (Discrete Wavelet Transform - DWT)

Transformadas Wavelet (*Wavelet transforms (WT)*) proporcionam um meio mais flexível para representar um sinal no domínio de tempo-frequência ao permitir a utilização de janelas de tamanho variável, sendo amplamente aplicada nas áreas de Engenharia biomédica para solucionar uma variedade de problemas. Por analisar sinais biológicos, como o EEG, em diferentes resoluções de tempo-frequência, WT é capaz de processá-los de modo eficiente durante a etapa de extração de características. [5]

De modo geral, a transformação wavelet de um sinal $x(n)$ pode ser definida no domínio contínuo como:

$$wt(s, \tau) = \frac{1}{\sqrt{s}} \int_{-\infty}^{+\infty} x(t) \Psi^*\left(\frac{t - \tau}{s}\right) dt \quad (3)$$

onde $\Psi^*(.)$ é o conjugado complexo da função $\Psi(.)$ escalada e deslocada. Enquanto o parâmetro s é responsável por esticar a função wavelet (o processo de dilatação), o parâmetro τ a desloca ao longo do eixo do tempo (o processo de translação). De maneira específica, a família de wavelets escaladas e deslocadas pode ser definida como:

$$wt(s, \tau) = \frac{1}{\sqrt{s}} x(t) \Psi\left(\frac{t - \tau}{s}\right), s > 0, \tau \in R \quad (4)$$

De acordo com o *framework* geral de Transformada contínua de Wavelet (*Continuous Wavelet Transform - CWT*), ambos s e τ podem ser variados de maneira contínua, no entanto, essa abordagem resulta em informação redundante além do grande custo computacional de tempo e alocação de memória. Nesse caso, tornar discretos os parâmetros de escala e translação permite reduzir a redundância. [6]

Para fazer análise no domínio de tempo-frequência de um sinal EEG $x(n)$, utilizamos a (*Discrete Wavelet Transform - DWT*). O objetivo principal dessa análise é evidenciar os detalhes do sinal por meio de um processo de decomposição. Nesse processo são produzidos subbandas chamadas coeficientes wavelets utilizando filtros complementares, filtro passa-baixa $g[n]$ e filtro passa-alta $h[n]$. Fundamentalmente, a DWT produz duas faixas de frequências com diferentes resoluções e escalas em cada nível da decomposição. [6] Obtemos a DWT a partir da discretização dos parâmetros apresentados em 3:

$$DWT(j, k) = \frac{1}{\sqrt{2^j}} \int_{-\infty}^{+\infty} x(t) \Psi\left(\frac{t - 2^j k}{2^j}\right) dt \quad (5)$$

Cada nível consiste de dois filtros digitais e dois redutores de qualidade (*downsamplers*) numa escala de 2. As saídas dos redutores do primeiro filtro passa-alta e do primeiro filtro passa-baixa produzem os coeficientes detalhados D1 e os coeficientes de aproximação A1, respectivamente. A cada nível do processo de decomposição, a resolução da frequência é dobrada através da filtragem e a resolução do tempo é reduzida pela metade através da redução de qualidade. A 1 representa a decomposição wavelet em 5 níveis de um sinal. Os coeficientes A1, D1, A2, D2, A3, D3, A4, D4, A5 e D5 e suas respectivas faixas de frequência estão listados na 1, onde fs é a frequência de amostragem original do sinal de entrada $x(t)$. [5]

TABLE 1
Subbands de frequência para decomposição wavelet em 5 níveis

Coeficientes	Faixa de Frequência
A1	0 - $fs/4$
D1	$fs/4$ - $fs/2$
A2	0 - $fs/8$
D2	$fs/8$ - $fs/4$
A3	0 - $fs/16$
D3	$fs/16$ - $fs/8$
A4	0 - $fs/32$
D4	$fs/32$ - $fs/16$
A5	0 - $fs/64$
D5	$fs/2$ - $fs/4$

A escolha da wavelet apropriada e o número de níveis de decomposição é muito importante na análise de sinais usando a DWT. O número de níveis de decomposição é definido com base nos componentes da frequência dominante do sinal. Os níveis são escolhidos de modo que as partes do sinal que se correlacionam bem com as frequências necessárias para a classificação do sinal sejam retidas nos coeficientes wavelet. Como os sinais do EEG não possuem nenhum componente de frequência útil acima de 30 Hz (artigo base fala 60!), o número de níveis adotado foi 5. Assim, o sinal é decomposto nos detalhes D1-D5 e uma aproximação final, A5. Estes coeficientes de aproximação e coeficientes detalhes são reconstruídos a partir do filtro de wavelet Daubechies 4 (DB4) [5].

REFERÊNCIAS

- [1] N. Huang, Z. Shen, S. Long, M. Wu, H. Shih, Q. Zheng, N. Yen, C. Tung, and H. Liu, "The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis," *PROCEEDINGS OF THE ROYAL SOCIETY A-MATHEMATICAL PHYSICAL AND ENGINEERING SCIENCES*, vol. 454, no. 1971, pp. 903–995, MAR 8 1998.
- [2] S. Li, W. Zhou, Q. Yuan, S. Geng, and D. Cai, "Feature extraction and recognition of ictal eeg using emd and svm," *Computers in Biology and Medicine*, vol. 43, no. 7, pp. 807–816, 2013.
- [3] D. Trad, T. Al-Ani, and M. Jemni, "A feature extraction technique of eeg based on emd-bp for motor imagery classification in bci," 2016.
- [4] Y. Lu, Y. Ma, C. Chen, and Y. Wang, "Classification of single-channel eeg signals for epileptic seizures detection based on hybrid features," *Technology and Health Care*, vol. 26, no. S1, pp. S337–S346, 2018.
- [5] A. Sharmila and P. Mahalakshmi, "Wavelet-based feature extraction for classification of epileptic seizure eeg signal," *Journal of Medical Engineering and Technology*, vol. 41, no. 8, pp. 670–680, 2017.
- [6] O. Kocadagli and R. Langari, "Classification of eeg signals for epileptic seizures using hybrid artificial neural networks based wavelet transforms and fuzzy relations," *Expert Systems with Applications*, vol. 88, pp. 419–434, 2017.

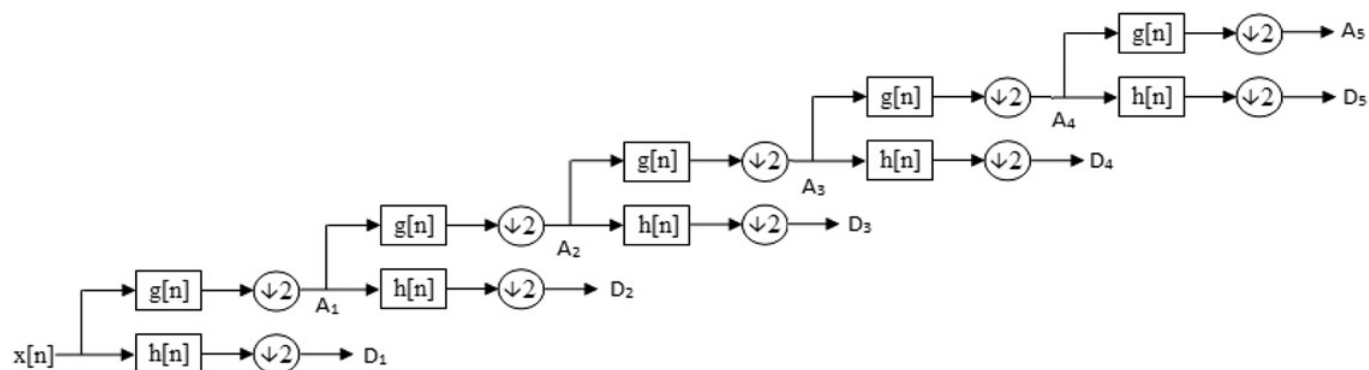


Fig. 1. Decomposição wavelet em 5 níveis para um sinal de EEG